

计算机听觉

张长水

清华大学 自动化系

zcs@mail.tsinghua.edu.cn

计算机听觉和计算机视觉

- 听觉：通过“听”
- ”Where?”
- Who?
- What?

- 视觉：通过“看”
- Where?
- Who?
- What?



声音:

对声音:

- 产生、改变
- 传输、记录



Create: Bone Flutes (7000 B.C.)




Modify: Delphi Theater (300 B.C.)



Record: Cylinder Phonograph (1899)

Transmit:
Crystal Radio
(1914)



计算机听觉的任务

与声音类型无关

- 声音定位
- 声音分离



计算机听觉的任务

语音

- 语音合成
- 语音识别
- 说话人识别
- 语音情绪识别

音乐

- 乐器识别  
- 作曲家识别
- 和弦识别
- 自动记谱
- 音乐生成

环境音



- 声音时间检测和识别

声音基本概念

- 振幅 (amplitude)
- 频率 (frequency)
- 周期 (Period)

$$T=1/f$$

五线谱与键盘对



$$x(t) = A \sin(2\pi f t + \varphi)$$


↑ ↑ ↑ ↑
时间 振幅 频率 相位

440Hz




声音的叠加


- 几个声源同时发声




计算得到声音的频率




傅里叶变换



(a)




傅里叶变换



(b)

计算得到声音的频率



傅里叶变换
(Fourier transform)

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-j2\pi f t} dt$$


和谐的声音

- 和谐的声音 (harmonious sound)
- 主要频率是某一个基频的整数倍

• $220 + 660 + 1100$ 和谐




• $220 + 375 + 770$ 不和谐



不和谐的声音



- 噪声：随机选定了100个频率的正弦波： $100 < f < 10000$.



- 锣




人声是和谐的吗？



(Thanks to Robert Remez)


频谱图

violin




频谱图


female



频谱图 (叠加的声音)




频谱图 (叠加的声音)





音高

- 音高 (pitch) :一个主观的感受
- 针对和谐的声音的
- 由基频定义
- 基频 (fundamental frequency) : 所有频率里最低的比较强的频率。





音色



- 和主要频率分布有关



Classify Sounds by Harmonicity



Oboe





Clarinet





Classify Sounds by Harmonicity

- Somewhat harmonic (quasi-harmonic)



Marimba





Human voice



Classify Sounds by Harmonicity

- Inharmonic




Gong




Sounds	Instrument family	Instruments
Harmonic	Woodwind	Piccolo, flute, oboe, clarinet, bassoon, saxophone
	Brass	Trumpet, horn, euphonium, trombone, tuba
	Arco string	Violin, viola, cello, double bass
	Pluck string	Piano, guitar, harp, celesta
	Vocal	Voiced phonemes
Quasi-harmonic	Pitched percussive	Timpani, marimba, vibraphone, xylophone
Inharmonic	Non-pitched percussive	Drums, cymbal, gong, tambourine

传统方法

- 以语音识别为例
- 计算频谱图
- 提取梅尔倒谱系数
- 音素：发音基本单位
- 爱“a-i”，百“b-a-i”
- 音素转化为词“b-a-i-h-e”百合
- 词到句子

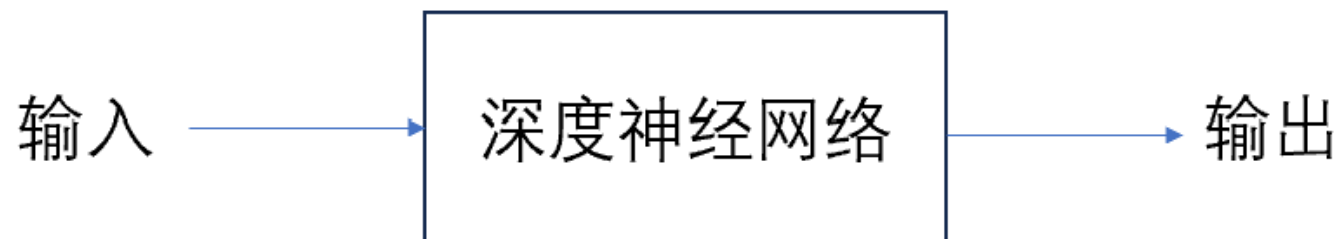



自动语音识别



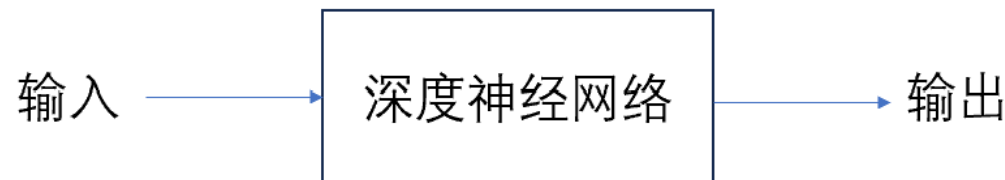
深度学习方法

- 计算频谱图
- 提取梅尔倒谱系数?
- 采集和标注大量的样本训练模型



用深度学习方法做环境音分类

- 收集消防车鸣笛声和婴儿的哭声数据
- 把所有声音切成等时间长度的音频，计算频谱图
- 构建一个深度卷积神经网络模型，输入是频谱图，输出层有两个节点，消防车鸣笛声[1,0]和婴儿的哭声[0,1]。
- 训练这个神经网络，直到网络收敛。
- 使用新的这两类数据对这个模型做测试。





模型

神经网络模型

- CNN
- RNN
- LSTM
- Transformer

序列神经网络模型

- Recurrent Neural Network (RNN)
- 递归神经网络
- 循环神经网络
- 建模数据的先后关系
- Song shu $\checkmark$
- Song dong $\checkmark$
- Song bo $\times$
- Tao shu $\checkmark$




举例：RNN网络前向计算

1维情况， s 和 y 的激活函数 f 和 g 为全等函数， $b=0$

设 $w_x = 0.2$ ， $w_v = 0.5$ ， $v = 0.1$ ；令 s 初始化为 $s_0 = 0$ 。输入序列长度为2。


- 输入 $x_1 = 1.0$
- $s_1 = f(w_v s_0 + b_v + w_x x + b_x) = w_v s_0 + b_v + w_x x + b_x$
 $= 0.5 * 0 + 0.2 * 1.0 = 0.2$
- 第一时刻的输出 $y_1 = g(v s_1 + b_s) = v s_1 + b_s = 0.1 * 0.2 = 0.02$ 。
- 输入 $x_2 = 0.2$ ，此时 s 已经在第一时刻的计算中被更新，因此
- $s_2 = f(w_v s_1 + b_v + w_x x + b_x) = 0.5 * 0.2 + 0.2 * 0.2 = 0.1 + 0.04 = 0.14$
- 第二时刻的输出 $y_2 = g(v s_2 + b_s) = 0.1 * 0.14 = 0.014$



序列神经网络模型

- Long Short-Term Memory (LSTM)
- 长短时记忆模型
- 门 (gate) 的作用

$$\begin{aligned}i_t &= \sigma(W_{ii}x_t + b_{ii} + W_{hi}h_{t-1} + b_{hi}), \\f_t &= \sigma(W_{if}x_t + b_{if} + W_{hf}h_{t-1} + b_{hf}), \\g_t &= \tanh(W_{ig}x_t + b_{ig} + W_{hg}h_{t-1} + b_{hg}), \\o_t &= \sigma(W_{io}x_t + b_{io} + W_{ho}h_{t-1} + b_{ho}), \\c_t &= f_t \odot c_{t-1} + i_t \odot g_t, \\h_t &= o_t \odot \tanh(c_t).\end{aligned}$$



技术现状： 语音合成

已经在成功应用， 可以改进

- 一个孩子， 一两黄瓜
- 一会儿
- 古董、古代
- 学数数、数数看


方向 (Adaptive, Robust, Fast, Low-resource, Expressive)

- 具有丰富表现力的语音合成
- 快速
- 低资源需求

技术现状： 语音识别

存在问题

- 新词
- 背景噪声
- 小人群口音
- 多语言混杂







技术现状： 音乐信号

困难： 声音的叠加

- 和弦识别
- 自动记谱
- 自动作曲： 长时间音乐生成



交响乐《长征组歌》
八、祝 捷

稍快 湖南民歌风、乐观、诙谐地

长笛
双簧管
单簧管
大管
小提琴
中提琴
大提琴
低音提琴
定音鼓
(A.C.E.)
中音鼓
小军鼓
钹
小钹
小钹口
中钹
大钹
低音钹

稍快 湖南民歌风、乐观、诙谐地

小鼓
小钹口
中钹
大钹
低音钹

本曲谱上传于 中国曲谱网

技术现状

- 环境音识别
- 声音分离

J. Brahms,
Clarinet Quintet in B minor,
op.115. 3rd movement




计算机视觉与计算机听觉


- 视觉的困难：物体遮挡
- 听觉的困难：声音叠加
- 视觉：表现具象物体
- 听觉：表现情绪



原始淡入淡出视频



叠加权重



缩放因子



恢复得到的视频

• Demo 生成音乐

流行舞曲与朗朗上口的旋律，热带打击乐，明快的节奏



爵士乐，有萨克斯管独奏，钢琴、弦乐和鼓



摇滚乐，有着过载音的吉他，一个沉重的贝斯，疯狂的鼓点



长达两分钟的音乐，速度较慢，有电子乐元素



长达两分钟的音乐，一个宏大的管弦乐合奏，雷声般的打击乐器，史诗般的铜管喇叭声，以及飞舞的弦乐，创造了像战斗史诗的电影氛围。



《我不想上班》

智谱清言作词

SUNO AI演唱

不愿随波逐流

音乐天才莫扎特

- “In Rome, he (14 years old) heard Gregorio Allegri's *Miserere* **once** in performance in the Sistine Chapel. He wrote it out **entirely from memory**, only returning to correct **minor errors...**”

-- Gutman, Robert (2000). *Mozart: A Cultural Biography*

<http://www.ncpa-classic.com/2012/10/26/VIDA1351237690135388.shtml#2>



Wolfgang Amadeus Mozart

- 计算机能达到这个水平吗？

知识点

- 计算机听觉要解决什么问题？
- 声音的属性。
- 深度学习识别声音的流程。
- 理解RNN，LSTM的基本操作和作用。
- 当前技术的水平怎样？
- 为什么听觉问题非常难？
 - 声音的叠加

谢谢