

自然语言处理 与理解

张长水

清华大学 自动化系


zcs@mail.tsinghua.edu.cn

为什么要研究自然语言？



- 自然语言与人工语言
- 自然语言是一种与^人交流的自然方式
 - 智能体(智能系统, 智能产品)与^人交流
- 语言是智能的一个重要方面
- 有助于研究人脑和智能
- 有时：语言并非唯一的交流方式，也不是最好的方式

词的表示：传统表示方法



- 字符串：“牡丹花”，“school”
 - 独热向量（one-hot vectors）
 - 牡丹花 = $[1\ 0\ 0]$
 - 玫瑰花 = $[0\ 1\ 0]$
 - 北京 = $[0\ 0\ 1]$
-
- 向量维数等于字典大小（如1万，10万）
 - 不反映词之间的关系



词向量



- 向量之间距离
- 词之间的相似性



- 词向量 (Word vectors) ， 词嵌入 (word embeddings) ， 词表示 (word representations)
- 牡丹花=[0.281 0.792 -0.155 0.101 0.220 0.343 0.221].

方法：基于深度学习的方法 (2010-)

神经网络：


- LSTM
- Transformer



- 输入到输出端到端训练



Transformer: Encoder-Decoder 框架

- 输入: x_1, x_2, x_3, x_4 (字词序列)
- 输出: 句子 y_1, y_2, y_3





Transformer: Encoder-Decoder 框架

- 输入: x_1, x_2, x_3, x_4 (字词序列)
- 输出: 句子 y_1, y_2, y_3
- 编码后的语义向量
- 先理解, 再翻译



Transformer: 多层编解码结构

- 多层编码，多层解码



注意力


- 硬注意力 (hard attention)
- 软注意力 (soft attention)

$$V(x) = \sum_{n=1}^m w_n V_n$$

- 权重取值




8头注意力





自注意力

- 自注意力 (self-attention)
 - 权重取值
 - “它” 的注意力在 “峨眉山”
 - “它” 的注意力在 “猴子”
 - “它” 的注意力在 “吃”
 - “它” 的注意力在 “饿”
-
- $V(x) = \sum_{n=1}^m w_n V_n$
 - 有助于理解语言



自注意力-多头注意力

- 自注意力 (self-attention) $V(x) = \sum_{n=1}^m w_n V_n$
- 多头 (Multi-head)
- 注意力权重是学习得到的




词的表示： 向量表示方法

“You shall know a word by the company it keeps” (J. R. Firth 1957: 11)


- 每一个词含义由其上下文决定
- “这本书没意思”，“不好意思，让你久等了”
- Go to the bank to deposit money
- Go to the bank to see the scenery



Transformer-Decoder



Transformer-Decoder



OpenAI: ChatGPT

- GPT (Generative Pre-trained Transformer) , OpenAI, 2018, 6
- GPT-2、 GPT-3 (2020) 、 ChatGPT (2022) 、 ChatGPT4 (2023)
- GPT-4 GPT3的10倍大小
- ~1.8 trillion, ~175 billion, 120 层, 96层
- 预测下一个词: 自监督学习
- “清华大学自动化系模式识别研究所”
- “清华” -> “大学”
- “清华大学” -> “自动化”
- 生成顺畅的语句



机器自动翻译举例(2015年前)

- 会议，研讨会，演讲和讨论代表频繁地需要以后被检索和被回顾信息交换的口头形式。人被生产的分钟典型地提供手段为这样的检索，但是昂贵生产和倾向于由周详接受人或记者的个人偏心变形。

机器自动翻译举例(2015年前)

- Meetings, seminars, lectures and discussions represent verbal forms of information exchange that frequently need to be retrieved and reviewed later on. Human-produced minutes typically provide a means for such retrieval, but are costly to produce and tend to be distorted by the personal bias of the minute taker or reporter.
- 会议, 研讨会, 演讲和讨论代表频繁地需要以后被检索和被回顾信息交换的口头形式。人被生产的分钟典型地提供手段为这样的检索, 但是昂贵生产和倾向于由周详接受人或记者的个人偏心变形。

机器自动翻译举例(2020年百度)

- Meetings, seminars, lectures and discussions represent verbal forms of information exchange that frequently need to be retrieved and reviewed later on. Human-produced minutes typically provide a means for such retrieval, but are costly to produce and tend to be distorted by the personal bias of the minute taker or reporter.
- 会议、研讨会、讲座和讨论是口头形式的信息交流，经常需要在以后检索和审查。人工制作的会议记录通常为这种检索提供了一种手段，但制作成本很高，而且容易被记录者或报告者的个人偏见所扭曲。

预训练模型与微调

OpenAI, GPT3:

- 数据: 45Tb
- 用电和花费
- 数据: 不足以解决实际需求
- 缺少人的评价
- ChatGPT:使用更多的数据训练GPT3(微调)

OpenAI: ChatGPT

- 提示学习 (Prompt Learning)
- “我喜欢这本书”：情感分类
- “我喜欢这本书”：语法分类
- “我喜欢这本书”：文本分类

- “我喜欢这本书,我的情感是_” 输出是：正面。

OpenAI: ChatGPT

1. 用提示学习的数据集的一部分，请人专门标注提示的答案。并用这些标注好的数据在GPT3的基础上训练网络。
2. 用模型生成多个答案。请人对这些答案的好坏排序。利用这些带有排序信息的数据训练另一个模型来自动评判答案好坏。
3. 采用强化学习方法继续优化GPT3模型。

提示学习

一个模型完成所有任务：

- “请把下面句子翻译成英文：”
- “告诉我中国刺绣的简单历史”
- “写一首2025年欢度春节的七言绝句”

- 通用性: 通用人工智能
- 生成式人工智能

预训练模型与微调

- 规模定律，或缩放定律、规模化法则、尺度定律（Scaling Law）

垂类模型

- 收集行业数据，微调一个模型，如航空航天大模型
- 基础模型，或基座模型（Foundation Model）



ChatGPT的问题

- 逻辑推理能力弱
- 推理数据少

ChatGPT (2023,2)



11122243786 加上 564876219760 结果是多少?



$11122243786 + 564876219760 = 575988653546.$



$11122243786 + 564876219760 = ?$



$11122243786 + 564876219760 = 575988653546.$

百度Ai+

哪吒2 (《哪吒之魔童闹海》) 已经上映了29天。


上映日期:

- 哪吒2于2025年1月29日 (即2025年大年初一) 在中国大陆上映 ¹ ² 。

计算上映时长:

- 从2025年1月29日至2025年2月16日, 共计29天。

因此, 哪吒2截至2025年2月16日已经上映了29天。



分享

收起 ^

哪吒上映多少天了?



百度一下

Q 网页

Ai+

图片

资讯

视频

笔记

地图

贴吧

文库

更多

百度为您找到以下结果

搜索工具

百度Ai+

听


24天

电影[《哪吒之魔童闹海》]上映了24天 ¹ ²。该电影自上映以来, 票房表现非常出色, 截至2月24日, 总票房已经突破125亿 ¹ ²。此外, 电影在全球范围内的表现也非常亮眼, 特别是在海外市场, 如澳大利亚^Q、新西兰^Q和北美^Q等地都取得了不错的票房成绩 ³。

百度(2025,2,24)

ChatGPT o1

- 增强了推理能力
- 使用了大量推理数据
- 推理能力显著提高



DeepSeek R1


- 复杂的新技术
- 模型
- 数据
- 算力
- 和O1相当的性能

- 开源



Grok 3_(2025,2,18)

- 10万块H100芯片， 122天
- 20万块， 92天
- 用电100兆瓦
- 对标o3



GPT-5

- **数学领域**: 在 2025 年 AIME 测试中无工具辅助达到 94.6%
- **实际编程应用**: SWE-bench Verified 达到 74.9%, Aider Polyglot 达到 88%
- **多模态理解**: MMMU 达到 84.2%
- **健康领域**: HealthBench Hard 达到 46.2%

(Coding, Hard Prompts, Creativity)

Model	224 / 224	Overall	Hard Prompts	Coding	Math	Creative Writing	Instruction Following	Longer Query	Multi-Turn
gpt-5	1	1	1	1	1	1	1	1	1
gemini-2.5-pro	2	2	2	2	1	1	2	1	1
o3-2025-04-16	2	2	2	2	2	5	4	6	5
chatgpt-4o-latest-2...	3	3	3	2	10	2	3	2	1
gpt-4.5-preview-202...	4	4	4	3	5	2	3	2	1
grok-4-0709	5	5	5	7	1	2	3	5	5
qwen3-235b-a22b-ins...	5	2	1	1	1	2	2	2	3
claude-opus-4-20250...	6	3	2	5	2	2	1	5	5
glm-4.5	6	3	3	5	5	3	6	6	6
kimi-k2-0711-preview	6	4	3	8	8	11	8	5	5
deepseek-r1-0528	7	4	3	6	6	11	8	8	8
claude-opus-4-20250...	8	6	6	6	2	4	1	5	5
gemini-2.5-flash	10	13	19	5	3	8	6	11	11
gpt-4.1-2025-04-14	10	7	8	25	5	6	4	5	5
grok-3-preview-02-24	10	7	12	16	5	6	5	9	9
qwen3-235b-a22b-thi...	11	7	5	3	5	5	8	8	8
claude-sonnet-4-202...	14	7	3	5	6	4	2	5	5
qwen3-235b-a22b-no-...	14	13	8	6	16	18	14	8	8
o1-2024-12-17	15	13	16	6	12	10	10	20	20
o4-mini-2025-04-16	15	16	14	5	23	20	25	17	17


GPT-5

- 逻辑推理问题

SWE-bench Verified

Software engineering

○ Without thinking ● With thinking



GPT-5

- 用户问了一下，Gpt 5说他也是人也会看错，他把 5.11 看成了 6.11
- 逻辑推理问题



Solve:

$$5.9 = x + 5.11$$

$$5.9 = x + 5.11$$

Subtract 5.11 from both sides:

$$x = 5.9 - 5.11$$

$$x = -0.21$$

Answer: -0.21



当前大语言存在的问题

长期

- 可解释性比较差：回答不了“为什么出现这种翻译错误？”
- 缺少符号和逻辑的学习机制：今后还会继续发展

当前大语言存在的问题



- “知识碎片”的拼接
- 创作和“幻觉”：共同的机理
- 大模型的使用：会出错

应用

- RAG (Retrieval-augmented Generation)

扩展检索

- 查询：政策，资料，法律，法规



深度学习方法缺点 (2022)

- 他穿的左一件右一件
- He wears one on the left and one on the right
- 那里的人里三层外三层
- The people there are three floors inside and three floors outside
- 铁齿铜牙
- Iron teeth and copper teeth
- 不知道东南西北了
- I don't know the southeast and northwest

深度学习方法缺点 (2023,3)

SE

翻译成英文：

他穿的左一件右一件
那里的人里三层外三层
铁齿铜牙
我已经不知道东南西北了
这条街比较长



He's wearing one on the left and one on the right.
People there are layered inside and outside.
Iron teeth and bronze teeth.
I've lost my sense of direction.
This street is quite long.



把木兰辞中：东市买骏马，西市买鞍鞯，
南市买辔头，北市买长鞭 翻译成英语

Purchase a steed in the eastern market,
Buy a saddle and bridle in the western market,
Purchase reins in the southern market,
Acquire a long whip in the northern market.

(2025,7,16)

生成文本的评价

- 人工评价是金标准

人工评价的困难

- 慢、代价昂贵
- 不一致
- 可能会出错
-