



机器学习

张长水

清华大学 自动化系



2 Million Flickr Images







[Slide credit: Alexei Efros]



[Slide credit: Alexei Efros]




[Slide credit: Alexei Efros]




[Slide credit: Alexei Efros]

为什么可以这样做？





2万图像中的近似图



200万图像中的近似图

机器学习的思想

- 数学对于世界的解释：物理、化学、天文学
 - 欧姆定律
 - 天体运行规律
- 复杂的客观世界
 - 心理学、经济学等
- 数据
 - 图像识别
 - 语音识别
 - 机器翻译
 - ...



几个基本的学习任务



机器学习：实际应用中的常见问题

图像分类、音乐分类、文本分类……

- 回归：物体检测
- 分类：图像识别、语音识别
- 聚类
- 强化学习

回归

- 一些长条物体
- 其重量 y 与长度 x 有关
- 把重量 y 看做是长度 x 的函数 f
- 函数 f 未知
- 如果已知 x, y 的一些取值, 考虑由此找到 f



回归

- 图像中玫瑰花检测：确定方框
- 方框和花的颜色、纹理、形状特征有关
- 把方框看做是颜色、纹理、形状的函数 f
- 函数 f 未知
- 如果已知颜色、纹理、形状和边框的一些取值，考虑由此找到 f



回归

回归 (regression)

- 连续变量 y 的取值和某些变量 $x_1, x_2, \dots, x_m$ 有关
- 把 y 看做是 $x_1, x_2, \dots, x_m$ 的函数,

$$y = f(x_1, x_2, \dots, x_m)$$



- 函数 f 未知
- 如果已知 $x_1, x_2, \dots, x_m, y$ 的一些取值, 考虑由此找到 f

线性回归

- 观察发现, 函数 f 可以“近似”地用一个线性函数表示

$$y = \theta_1 x + \theta_0$$

- 这是对该问题的假设(并不知道真实的函数关系)
- “近似”: 存在误差
- 假设空间(hypothesis space): θ_1, θ_0 所有取值





线性回归

- 找到最好的 θ_1, θ_0 使得函数对数据拟合的好
- 度量拟合好坏: $(\hat{y} - y)^2$
- 总的度量: $L = \sum_{i=1}^N (\hat{y}_i - y_i)^2$
- 建模为一个优化问题:

$$\theta^* = \arg \min_{\theta} \sum_{i=1}^N (f_{\theta}(x^{(i)}) - y^{(i)})^2 \text{ ---- 最小二乘 (least squares)}$$

$$= \arg \min_{\theta} \sum_{i=1}^N (\theta_1 x^{(i)} + \theta_0 - y^{(i)})^2 \text{ ---- 线性最小二乘 (linear least squares)}$$



线性回归

- 已知4个长条形物体的长度 x 和重量 y 分别为
(1, 6), (2, 5), (3, 7), (4, 10)
- 将 x, y 间的函数关系设为 $y = \theta_1 x + \theta_0$

线性回归

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{pmatrix} \quad \boldsymbol{\theta} = \begin{pmatrix} \theta_1 \\ \theta_0 \end{pmatrix} \quad \mathbf{y} = \begin{pmatrix} 6 \\ 5 \\ 7 \\ 10 \end{pmatrix}$$

- 把上面数据代入公式: $\boldsymbol{\theta}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$

$$\begin{aligned} \bullet \quad \boldsymbol{\theta}^* &= \left(\begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{pmatrix}^T \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{pmatrix} \right)^{-1} \begin{pmatrix} 1 & 1 \\ 2 & 1 \\ 3 & 1 \\ 4 & 1 \end{pmatrix}^T \begin{pmatrix} 6 \\ 5 \\ 7 \\ 10 \end{pmatrix} \\ &= \begin{pmatrix} 30 & 10 \\ 10 & 4 \end{pmatrix}^{-1} \begin{pmatrix} 77 \\ 28 \end{pmatrix} = \begin{pmatrix} 0.2 & -0.5 \\ -0.5 & 1.5 \end{pmatrix} \begin{pmatrix} 77 \\ 28 \end{pmatrix} = \begin{pmatrix} 1.4 \\ 3.5 \end{pmatrix} \end{aligned}$$

- 函数关系为 $y = 1.4x + 3.5$, 对长度为5的该类物体的重量预测为10.5。

分类

- 识别牡丹花和玫瑰花
- 由花的颜色、纹理、形状特征能确定是哪种花
- 把花的名称（离散变量）看做是颜色、纹理、形状的函数 f
- 函数 f 未知
- 如果已知玫瑰花的颜色、纹理、形状的一些取值，考虑由此找到 f



分类

分类 (classification)


- 离散变量 y 的取值和某些变量 $x_1, x_2, \dots, x_m$ 有关
- 把 y 看做是 $x_1, x_2, \dots, x_m$ 的函数,

$$y = f(x_1, x_2, \dots, x_m)$$

- 函数 f 未知
- 如果已知 $x_1, x_2, \dots, x_m, y$ 的一些取值, 考虑由此找到 f

图像识别

- 函数 f 可以用一个深度神经网络表示
- 这是对该问题的假设(并不知道真实的函数关系)
- 假设空间(hypothesis space): 深度神经网络参数的所有取值构成的函数



图像识别

- 找到最好的参数使得网络能识别这两种花
- 度量识别得好坏: $(\hat{y} - y)^2$
- 总的度量: $L = \sum_{i=1}^N (\hat{y}_i - y_i)^2$
- 建模为一个优化问题:
- 寻找神经网络参数使得 L 最小
- BP算法




图像识别

- 牡丹花: [1 0], 玫瑰花: [0 1]
- 输入一张牡丹花图像, 输出[0.9 0.1]
- $(\hat{y} - y)^2 = 0.1 * 0.1 + 0.1 * 0.1 = 0.02$
- 网络深, 网络宽, 神经网络模型的表达能力就非常强
- 图像足够多, 可以取得非常高的识别率



回归与分类






几个关键问题

- 如何表示输入和输出
 - 简单问题：图像识别
 - 了解对电话客服的满意度
- 确定目标函数
- 假设空间
- 优化方法
- 训练数据




过拟合与泛化

- 泛化 (generalization)
- 不知道真实模型
- 只有训练数据，希望拟合得尽可能好



过拟合与泛化

- 过拟合 (over fitting) : 训练误差小, 测试误差大
- 欠拟合 (underfitting) : 训练误差大, 测试误差大
- 拟合刚刚好 (Fitting just right) : 训练误差小, 测试误差小
- 训练集、验证集



同分布

- 基本假设：训练数据和测试数据同分布
- 同分布：统计学中的概念
- 同分布：两次抽取100个大学生，身高分布
- 不是同分布：抽取100个大学生，100个小学生，身高分布
- 同分布：分布差异随着样本数增加而减小

黑盒和白盒

- 黑盒：对于系统的工作机理不清楚。对数据依赖强。
 - 人脸识别系统
 - 语音识别系统
- 白盒：对于系统的工作机理清楚。对数据依赖弱。
 - 根据同材料的长条物体，根据长度预测重量
- 灰盒：对于系统的工作机理知道一部分

Tabular Prior-data Fitted Network (TabPFN)

Article

Accurate predictions on small data with a tabular foundation model

<https://doi.org/10.1038/s41586-024-08328-6>

Received: 17 May 2024

Accepted: 31 October 2024

Published online: 8 January 2025

Open access

 Check for updates

Noah Hollmann^{1,2,3,7}✉, Samuel Müller^{1,7}✉, Lennart Purucker¹, Arjun Krishnakumar¹, Max Körfer¹, Shi Bin Hoo¹, Robin Tibor Schirrmeister^{4,5} & Frank Hutter^{1,3,6}✉

Tabular data, spreadsheets organized in rows and columns, are ubiquitous across scientific fields, from biomedicine to particle physics to economics and climate science^{1,2}. The fundamental prediction task of filling in missing values of a label column based on the rest of the columns is essential for various applications as diverse as biomedical risk models, drug discovery and materials science. Although deep learning has revolutionized learning from raw data and led to numerous high-profile success stories^{3–5}, **gradient-boosted decision trees**^{6–9} have dominated tabular data for the past 20 years. Here we present the **Tabular Prior-data Fitted Network (TabPFN)**, a tabular foundation model that outperforms all previous methods on datasets with up to 10,000 samples by a wide margin, using substantially less training time. In 2.8 s, TabPFN outperforms an ensemble of the strongest baselines tuned for 4 h in a classification setting. **As a generative transformer-based foundation model, this model also allows fine-tuning, data generation, density estimation and learning reusable embeddings.** TabPFN is a learning algorithm that is itself learned across millions of synthetic datasets, demonstrating the power of this approach for algorithm development. By improving modelling abilities across diverse fields, TabPFN has the potential to accelerate scientific discovery and enhance important decision-making in various domains.



University of Freiburg, Freiburg, Germany.
Prior Labs

