



推理



张长水


清华大学 自动化系

zcs@mail.tsinghua.edu.cn



推理

- 早期人工智能研究的主要内容之一
- 定理自动证明
- Newell, Simon, Shaw: 逻辑理论机 (The Logic Theory Machine)



推理问题的表示

- 推理问题：已知条件和结论，给出推理过程
- 表示条件和结论


- 谓词

张小龙是清华大学一个学生：THStudent(张小龙)

THStudent: 便于记忆的名字

- 规则

If A Then B



推理举例

已知下面的条件：


1. $P \vee Q$
2. $P \rightarrow R$
3. $Q \rightarrow S$
4. $\sim S$

■ 请证明R是上面条件的逻辑推论。

证明：由上面条件和推理规则可以得到：

5. $\sim Q$ （根据条件3和4）
6. P （根据条件1和中间结论5）
7. R （根据条件2和中间结论6）

证明完毕。




推理技术的思路

- 推理问题：已知条件和结论，给出推理过程
- 表示一个待求解问题
- 给出一个推理算法：使用什么条件进行推理，得到什么推理结论



推理规则

- 根据已知条件，使用推理规则（基本推理单元）进行一步推理
- 几条推理规则：
 - 附加： $A \Rightarrow (A \vee B)$
 - 简化： $(A \wedge B) \Rightarrow A$
 - 假言推理： $((A \rightarrow B) \wedge A) \Rightarrow B$
 - 拒取式： $((A \rightarrow B) \wedge \sim B) \Rightarrow \sim A$
 - 析取三段论： $((A \vee B) \wedge \sim A) \Rightarrow B$
 - 假言三段论： $((A \rightarrow B) \wedge (B \rightarrow C)) \Rightarrow (A \rightarrow C)$



形式化推理

- 附加: $A \Rightarrow (A \vee B)$
- 该推理不依赖于A, B的具体内容
- A: "2是一个偶数", "太阳从东边升起"
- 形式化推理: 现实生活中各类推理问题背后的共同规律。

一个简单的推理算法

推理规则集合 C

■ 第一步：将已知条件放入集合 S_{old} .

第二步：考虑集合 S_{old} 中任何两个条件，根据 C 进行推理，将推理结果加入集合 S_{new} .

第三步：如果 S_{new} 为空，算法结束：得不到推理目标。

第四步：如果推理的目标在 S_{new} 中，算法结束：得到了推理目标。

第五步：考虑集合 S_{old} 中的一个条件和 S_{new} 中的一个条件，以及 S_{new} 中任何两个条件，根据 C 进行推理，并将推理结果加入集合 S_n .


第六步： $S_{old} = S_{old} \cup S_{new}$

第七步： $S_{new} = S_n$ 。回到第三步。

A B C D

E F G


H M N



关键问题1

- 使用什么推理规则？
- 遍历所有的规则

- 附加: $A \Rightarrow (A \vee B)$
- 简化: $(A \wedge B) \Rightarrow A$
- 假言推理: $((A \rightarrow B) \wedge A) \Rightarrow B$
- 拒取式: $((A \rightarrow B) \wedge \sim B) \Rightarrow \sim A$
- 析取三段论: $((A \vee B) \wedge \sim A) \Rightarrow B$
- 假言三段论: $((A \rightarrow B) \wedge (B \rightarrow C)) \Rightarrow (A \rightarrow C)$
- 等价三段论: $((A \leftrightarrow B) \wedge (B \leftrightarrow C)) \Rightarrow (A \leftrightarrow C)$
- 构造性二难: $(A \rightarrow B) \wedge (C \rightarrow D) \wedge (A \vee C) \Rightarrow (B \vee D)$




关键问题2

- 在已知条件和中间结论中，选择哪些条件进行推理？
- 遍历所有的条件对：利用搜索算法

A B C D


E F G

H M N




推理算法的性质

- 算法能找到问题的解吗？
 - 如果存在一个证明过程，是否一定可以给出这个证明过程？
- 算法的计算复杂度如何？
- 最优解？
 - 在推理研究中，人们对最优解的关注比较弱




几个推理方法

- 归结原理
- 基于规则的方法（正向推理、逆向推理）
- 时空推理
- 贝叶斯网络
-



几个推理方法

- 归结原理
 - 只使用一条规则进行推理
- 基于规则的方法
 - If A and B, 匹配A得到B



几个推理方法-时空推理

关于a、b、c、d、e五个物体有下面的5个描述：


- a在b的后边；
- e在b的前边；
- a在c的后边；
- d和c在同一排；
- a在d的前边。

这里面有一个是和其它矛盾的。请把矛盾的描述找出来。

贝叶斯网络（概率图模型）

已知所有事件关于其原因事件的条件分布

给定图谱中部分事件是否发生，推理图中剩余事件发生的概率



新任务


In $\triangle PQR$, $RS = 3$ and $QS = 14$. Find PS .

$$PS^2 = RS \cdot QS \quad \text{Theorem 8.2}$$

$$PS^2 = 3 \cdot 14 \quad RS = 3, QS = 14$$

$$PS^2 = 42 \quad \text{Simplify}$$

$$PS \approx 6.5 \quad \text{Positive square root}$$



A, B, C, D在争论今天是星期几。A说明天是周五，B说昨天是周日，C说你们俩都不对。D说今天是周六。这里只有一人说对了。问：今天是周几？

新任务

- 理解自然语言
- 理解数学语言
- 读懂几何图

- 转换成谓词，规则
- 再推理


In $\triangle PQR$, $RS = 3$ and $QS = 14$. Find PS .

$$PS^2 = RS \cdot QS \quad \text{Theorem 8.2}$$


$$PS^2 = 3 \cdot 14 \quad RS = 3, QS = 14$$

$$PS^2 = 42 \quad \text{Simplify}$$

$$PS \approx 6.5 \quad \text{Positive square root}$$



A, B, C, D在争论今天是星期几。A说明天是周五，B说昨天是周日，C说你们俩都不对。D说今天是周六。这里只有一人说对了。问：今天是周几？




挑战

感知

推理

- 感知过程会出错：反译推理（abductive reasoning）



In triangle ABC , $AD = 3$ and $BD = 14$. Find CD .

Choices:

A. 6.0 B. 6.5 C. 7.0 D. 8.5

Answer: B

Diagram Formal Language


```
Triangle(A,B,C)
Triangle(A,C,D)
Triangle(B,C,D)
PointLiesOnLine(D,Line(A,B))
Perpendicular(Line(A,C),Line(B,C))
Perpendicular(Line(C,D),Line(A,B))
```

Text Formal Language

```
Triangle(A,B,C)
Equals(LengthOf(Line(A,D)),3)
Equals(LengthOf(Line(B,D)),14)
Find(LengthOf(Line(C,D)))
```

挑战

- 得到的已知条件太多
- 任何两条相交直线：对顶角，补角
- 任何一个三角形：内角和，内角和外角
-



挑战

- 无法提前列出需要的所有知识
- 开放环境下的推理（Open world）



In $\triangle PQR$, $RS = 3$ and $QS = 14$. Find PS .


$$PS^2 = RS \cdot QS \quad \text{Theorem 8.2}$$

$$PS^2 = 3 \cdot 14 \quad RS = 3, QS = 14$$

$$PS^2 = 42 \quad \text{Simplify}$$

$$PS \approx 6.5 \quad \text{Positive square root}$$





新任务和新方法

- ChatGPT具有推理能力
- 贡献：不确定性推理，常识推理
- 新方法：使用大模型推理


BL

已知偶数可以被2整除，18是偶数，请问18可以被2整除吗？



是的，因为18是偶数，根据定义，偶数可以被2整除。因此，18可以被2整除，即18是2的倍数。





BL

我忘记女朋友的生日了，会导致什么？



忘记女朋友的生日可能会导致感情上的问题和不良后果。对许多人来说，生日是一个重要的庆祝日，特别是对于女性而言，她们往往期望在这个日子得到特别的关注和爱护。如果你忘记女朋友的生日，可能会让她感到被忽视和不重视，从而导致她的不满和不安。这可能会影响你们的关系，甚至会导致矛盾和分手。因此，如果你忘记了女朋友的生日，最好尽快道歉，向她表达你的歉意和爱意，并努力弥补过失。



YI

托马斯松从A班转到了B班，两个班级的平均智商都提高了，这可能么？



这是可能的。



假设A班的学生数量为 a ，平均智商为 x ，B班的学生数量为 b ，平均智商为 y 。

当托马斯松从A班转到B班后，A班的平均智商会下降，B班的平均智商会上升。但是，如果托马斯松的智商高于A班的平均智商 x ，并且低于B班的平均智商 y ，那么他的转班会使得A班和B班的平均智商都提高。

这是因为，从A班转到B班的托马斯松将带来以下影响：

1. A班中智商较低的学生数量减少，使得A班的平均智商上升。
2. B班中智商较高的学生数量增加，使得B班的平均智商上升。

因此，如果托马斯松的智商高于A班的平均智商 x ，并且低于B班的平均智商 y ，那么他的转班会使得A班和B班的平均智商都提高。

大模型推理会出现错误

BL

小明属猴，并且小明年龄在10岁到20岁之间，请问小明是哪年出生的？



根据您提供的信息，小明属猴并且年龄在10岁到20岁之间，那么可以推断出小明的出生年份应该在2028年到2018年之间。






具体的计算方法为，首先确定今年的年份是2023年，然后用今年的年份减去小明的年龄的上限20岁，得到小明最早可能出生的年份为 $2023 - 20 = 2003$ 年；再用今年的年份减去小明的年龄的下限10岁，得到小明最晚可能出生的年份为 $2023 - 10 = 2013$ 年。由于属猴的年份是出现在12年一个周期中的，因此小明出生年份的可能性为2016、2004和1992年，但是由于小明的年龄在10岁到20岁之间，因此小明的出生年份应该在2013年到2003年之间。


因此，小明出生的年份可能是在2013年到2003年之间的任意一年。

ChatGPT o1

- 增强了推理能力
- 使用了大量推理数据
- 推理能力显著提高



o1 greatly improves over GPT-4o on challenging reasoning benchmarks. Solid bars show pass@1 accuracy and the shaded region shows the performance of majority vote (consensus) with 64 samples.



DeepSeek R1

- 复杂的新技术
- 模型
- 数据
- 算力
- 和O1相当的性能





GPT-5

- 数学领域：在 2025 年 AIME 测试中无工具辅助达到 94.6%
- 实际编程应用：SWE-bench Verified 达到 74.9%，Aider Polyglot 达到 88%
- 多模态理解：MMMU 达到 84.2%
- 健康领域：HealthBench Hard 达到 46.2%

(Coding, Hard Prompts, Creativity)

Model	224 / 224	Overall	Hard Prompts	Coding	Math	Creative Writing	Instruction Following	Longer Query	Multi-Turn
gpt-5	1	1	1	1	1	1	1	1	1
gemini-2.5-pro	2	2	2	2	1	1	2	1	1
o3-2025-04-16	2	2	2	2	2	5	4	6	5
chatgpt-4o-latest-2...	3	3	3	2	10	2	3	2	1
gpt-4.5-preview-202...	4	4	4	3	5	2	3	2	1
grok-4-0709	5	5	5	7	1	2	3	5	5
qwen3-235b-a22b-ins...	5	2	1	1	1	2	2	2	3
claude-opus-4-20250...	6	3	2	5	2	2	1	5	5
glm-4.5	6	3	3	5	5	3	6	6	6
kimi-k2-0711-preview	6	4	3	8	8	11	8	5	5
deepseek-r1-0528	7	4	3	6	6	11	8	8	8
claude-opus-4-20250...	8	6	6	6	2	4	1	5	5
gemini-2.5-flash	10	13	19	5	3	8	6	11	11
gpt-4.1-2025-04-14	10	7	8	25	5	6	4	5	5
grok-3-preview-02-24	10	7	12	16	5	6	5	9	9
qwen3-235b-a22b-thi...	11	7	5	3	5	5	8	8	8
claude-sonnet-4-202...	14	7	3	5	6	4	2	5	5
qwen3-235b-a22b-no-...	14	13	8	6	16	18	14	8	8
o1-2024-12-17	15	13	16	6	12	10	10	20	20
o4-mini-2025-04-16	15	16	14	5	23	20	25	17	17

GPT-5


- 逻辑推理问题

GPT5(2025,8)

SWE-bench Verified

Software engineering

○ Without thinking ● With thinking



GPT-5

- 用户问了一下，Gpt 5 说他也是人也会看错，他把 5.11 看成了 6.11

- 逻辑推理问题

GPT5(2025,8)



ChatGPT 5 >



Solve:

$$5.9 = x + 5.11$$

$$5.9 = x + 5.11$$


Subtract 5.11 from both sides:

$$x = 5.9 - 5.11$$

$$x = -0.21$$

Answer: -0.21





出错

■ 2026,2

我想洗车，我家距离洗车店只有 50 米，你建议我是开车去还是走路去

走路去。

你家到洗车店 50 米，开车过去的“收益”几乎为零，反而多几个小坑：

- 更麻烦：上车、挪车、找位置、停好、交钥匙……流程比走过去长。
- 更容易把车再弄脏：哪怕就 50 米，路面灰、泥水、路边溅起的脏点，到了店门口又多一层“开场特效”。
- 更安全也更省心：近距离低速挪车其实更容易发生小剐蹭（行人、自行车、窄路口、倒车盲区）。
- 顺便当个超短散步：1 分钟不到，纯赚。

例外情况也有：外面在下大雨/冰雪很滑，或者你要带一堆重东西（例如车内要搬很多杂物清理），那就开过去（但这种情况下洗车本身也可能不划算）。

结论：正常天气，走路去最优解。

■ 数学推理 (Arithmetic Reasoning)

Mrs. Lim milks her cows **twice a day**. Yesterday **morning**, she got **68 gallons** of milk and in the **evening**, she got **82** gallons. This morning, she got **18 gallons** fewer than she had yesterday morning. After selling some gallons of milk in the afternoon, Mrs. Lim has only **24 gallons** left. How much was her revenue for the milk if each gallon costs **\$3.50**?

- 逻辑推理 (Logical Reasoning)
- **Metals** conduct electricity. Insulators do not conduct electricity. If something is made of **iron** then it is **metal**. **Nails** are made of **iron**. Is it true: **nails** conduct electricity?



推理问题


常识推理 (Commonsense Reasoning)

- Did Aristotle use a laptop?
- “The first laptop was invented in the modern era in 1980, later than Aristotle’s death,” and “A person cannot use a laptop if he had died before its invention.”
- 符号推理 (Symbolic Reasoning)
- Take the last letters of the words in ‘Natural Language Processing’ and then concatenate them.
- leg




存在问题

- ✓ 在一些任务上具有较高准确性
 - ✓ 神经网络直接处理自然语言，无需结构化
 - ✓ 大模型具有自然语言理解能力和一定常识知识
- 低可靠性
 - 要么将推理过程隐藏在端到端“黑盒”中
 - 要么生成看似正确但不可靠的推理过程




和推理相关的任务

- 自动定理证明
- 对话和问答
 - “亚里士多德用过电脑吗？”
 - “2的对数加22的对数是多少”



和推理相关的任务

- 一段事实：“清华大学的前身清华学堂始建于**1911**年，**1912**年更名为清华学校。**1928**年更名为国立清华大学。”（清华大学网页）
- 下面的话是否是事实：清华建校有**110**年了。
- 一段描述：孪生素数的证明
- 下面的话是否是事实：上述证明是正确的。




和推理相关的任务

事实确认 (Fact verification)

一段事实：“桌上有几个红富士苹果”。下面的陈述是否是事实：

- “桌上有苹果”。
- “桌上有水果”。
- “桌上有东西”。




和推理相关的任务

事实确认 (Fact verification)

一段事实：“小明在种植红富士苹果，他找到了红富士浇水、施肥生长的规律”。下面的陈述是否是事实：


- “小明找到了苹果生长规律”。
- “小明找到了水果生长规律”。
- “小明找到了事物变化规律”。



和推理相关的任务

事实确认 (Fact verification)

- 一段描述：孪生素数的证明
- 下面的话是否是事实：上述证明是正确的。




两个系统

- 符号系统

- 搜索、推理、知识表示、感知（视觉、听觉、语言）
 - 可解释性好

- 神经感知系统



两个系统

系统1:

快速，直觉，情感

自动，无意识，无努力

依赖经验，本能，联想

容易受到偏见和启发式的影响

适用于简单，熟悉，常见的问题.

系统2:

慢速，深刻，逻辑

有控制，有意识，有努力

依赖信息，推理，分析


可以避免或者纠正错误和偏见

适用于复杂，陌生，罕见的问题.

“Thinking, fast and slow” (Kahneman, 2011)

神经符号机（Neuro-Symbolic Machine）


- 感知+推理？
- 推理中嵌入感知？



张钊，朱军，苏航，迈向第三代人工智能，中国科学


因果推断

- 因果发现、学习、推断
- 相关、预测与因果
 - 公鸡叫->太阳就要升起了
 - 天气预报->要下雨了




ARC-AGI测试


- ARC-AGI-2: 静态推理
- 找规律



ARC-AGI测试

- ARC-AGI-3: 交互式推理
- 第一次遇到新问题
- 探索未知环境的主动性、构建世界模型的抽象能力、无指令下的目标识别，以及根据反馈修正行动的动态学习





谢谢