

可信的人工智能

Trustworthy AI

致谢

大量的内容、图片、数据等资料来自：

NLP and Society: Towards Socially Responsible NLP

Vinodkumar Prabhakaran, Research Scientist, Google

<https://web.stanford.edu/class/archive/cs/cs224n/cs224n.1204/index.html>

Trustworthy AI

Haochen Liu¹, Yiqi Wang¹, Wenqi Fan², Xiaorui Liu¹, Yaxin Li¹ and Jiliang Tang¹

¹Michigan State University, ²The Hong Kong Polytechnic University

Tutorial website: [Trustworthy AI: A Computational Perspective](#)

公平性

公平性： 例子

- 人工智能工具过滤简历
该过滤软件对一些职位更倾向于男性而“轻视”了女性。
- 原因
- 使用已有的职位简历训练模型

Amazon's Secret AI Hiring Tool Reportedly 'Penalized' Resumes With the Word 'Women's'



Rhett Jones

Yesterday 10:32am • Filed to: ALGORITHMS



22.3K 96

2



Photo: Getty

公平性

- 当前的人工智能算法要使用数据
- 数据中存在偏差（biases）
 - 数据收集
 - 数据标注

公平性

- 数据中存在偏差（biases）
- 数据量的差异：不平衡数据
 - 自然语言：小语种使用的人数不够多，训练数据就少
 - 因为他们人数少这一“弱势”导致他们得不到高科技带来的福利

公平性

- 数据中存在偏差 (biases)
- 数据量的差异：不平衡数据
- 数据报告中的偏差
 - 一些文档材料的词频统计

Word	Frequency in corpus
“spoke”	11,577,917
“laughed”	3,904,519
“murdered”	2,834,529
“inhaled”	984,613
“breathed”	725,034
“hugged”	610,040
“blinked”	390,692
“exhale”	168,985

公平性

- 数据中存在偏差 (biases)
- 数据量的差异：不平衡数据
- 数据报告中的偏差
- 数据选择中的偏差

World Englishes



Is the data we use to train our English NLP models representative of all the Englishes out there?

公平性

- 数据中存在偏差 (biases)

- 数据量的差异：不平

- 数据报告中的偏差

- 数据选择中的偏差

- 数据标注中的偏差



公平性

一种观点：

- 这些偏差是客观存在的
- 客观世界就是这样。

另一种观点：

- 谁要用这些数据？
- 这些数据被用于做什么？
- 使用这些数据会使得现状更糟还是变好？
- 如果因为历史数据中女性在某些职位人数少，就因此给女性就职的机会更少，这就是不公平的一种表现。

公平性度量

- 组间公平（group fairness）

各组各群体平等对待

- 个体公平（Individual Fairness）

个人平等对待

举例：全校分发电影票

- 每个系
- 每个人

公平性

- 公平算法
 - 不使用性别种族等信息
 - 图像识别的困难
 - 语音识别的困难



公平性

- 公平算法
- 公平度量
- 群体公平性：

$$\|P(\hat{Y} = 1|A = 0) - P(\hat{Y} = 1|A = 1)\| \leq \epsilon$$

- $A = 0$ 的群体被预测为正样本（被预测为录用）的概率（可能性）
- $A = 1$ 的群体被预测为正样本（被预测为录用）的概率（可能性）



隐私 Privacy

隐私数据

- 什么是隐私
- 隐私就是不希望别人知道的信息
- 敏感信息
- 涉及一个人的身体、身份、经历、肖像、健康、收入和行为等信息
- 一件事情对A是隐私，而对B可能不是隐私



隐私数据

- 数据中包含隐私信息
 - 医院
 - 银行
 - 证券公司
 - 键盘录入数据



模型中的隐私泄露风险

- 已知图像中人的名字
- 置信度
- 通过模型反推原始图像



隐私保护方法

- 差分隐私 (differential privacy)

- 例子：计算平均数

- $(A+B+C)/3 = E$

- $(A+B+C+D)/4 = F$

- $4 * F - 3 * E = D$

- 根据E，F可以推断出D

- 差分隐私保护：不能通过增加一条数据（或者减少一条数据）而破解出其中的数据


隐私保护方法

增加噪声来保护隐私数据

- 成绩查询系统: 同学的姓名、性别和考试成绩
- 考试成绩: 隐私数据
- 其他用户查询A同学的考试成绩, 不能返回A同学成绩
- 用户查询“全班女生的平均成绩”,
- 全班女生的平均成绩约为80分-100分

隐私保护方法

- 联邦学习
federated learning)
- 单一医院数据不足
- 数据不能离开医院



- “纵向联邦学习” (vertical federated learning)
- “横向联邦学习” (horizontal federated learning)

隐私保护方法

- 数据加密

安全与鲁棒

Safety & Robustness


安全

- 当前人工智能系统会出现错误
- 出错了怎么办？
- 会有哪些风险
- “在最坏情况下”

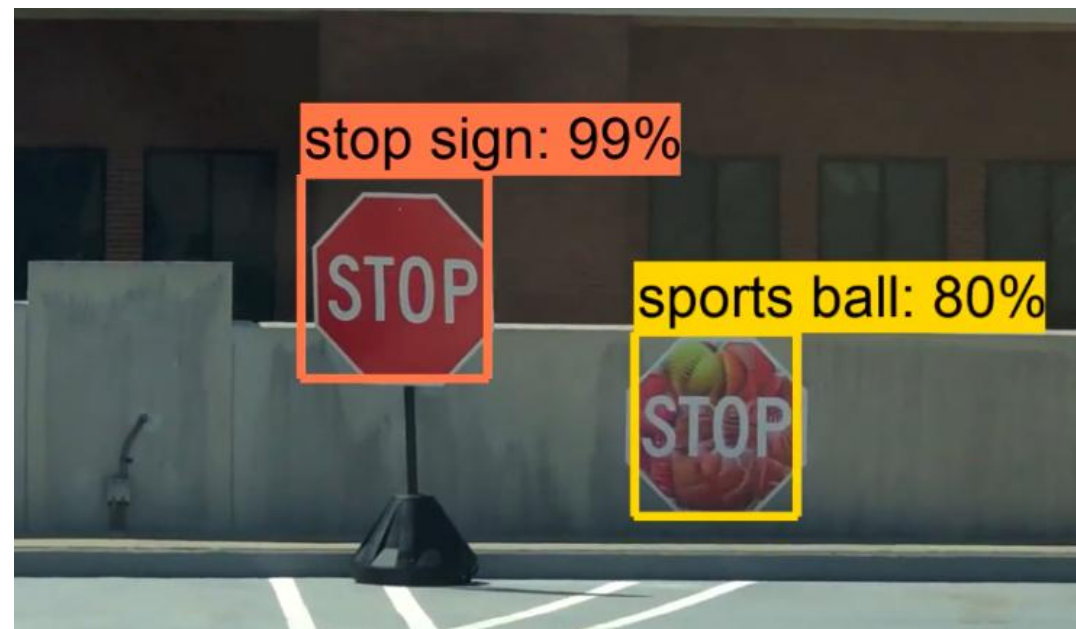


对抗攻击

- 深度神经网络对噪声很敏感
- 对抗攻击 (adversarial attack)



实际中的攻击



检测无人



检测有人



检测无人




对抗攻击与对抗防御

- 对抗攻击 (adversarial attack)

$$\max_{\|x_0 - x\| \leq \epsilon} \|f(x) - y_0\|$$

- 对抗防御 (adversarial defense)

$$\min_w \sum_{x_0, y_0 \in D} \max_{\|x_0 - x\| \leq \epsilon} \|f_w(x) - y_0\|$$




可解释性


Explainability & Interpretability

可解释性

- 图像识别系统：这个病人得了癌症
- 大夫：“为什么说病人得了癌症？”
- 了解原因，为进一步治疗提供依据
- 大夫对这个病人的诊断负有责任




- 为什么这个系统会做出这样的判断？
- 为什么会出错？
- 什么情况下会出错？



可解释性

- **Explainability**

- 模型本身不可解释: 黑盒系统
- 赋予一个解释





- **Interpretability:**

- 模型本身具有可解释性


- If (sunny and hot) then go swim
- Else if (sunny and cold) then go ski
- Else then go work

可解释性Explainability



Simple ConvNet for MNIST [LeCun 1998], 1993,1994,1995

可解释性Explainability



Understanding Neural Networks Through Deep Visualization

保护环境

Environmental

Well- being

训练大模型的电能消耗

ChatGPT:
1200万美元, 90万度电

二氧化碳排放量




Consumption	CO ₂ e (lbs)
Air travel, 1 passenger, NY↔SF	1984
Human life, avg, 1 year	11,023
American life, avg, 1 year	36,156
Car, avg incl. fuel, 1 lifetime	126,000

Training one model (GPU)	
NLP pipeline (parsing, SRL)	39
w/ tuning & experimentation	78,468
Transformer (big)	192
w/ neural architecture search	626,155

降低能源消耗


- 模型压缩
 - 在很多情况下，模型小一点性能损失不大
- 根据实际问题设计模型
- 设计专门的硬件



可问责性

Accountability


GPT-3 的一段对话



the patient: “Hey, I feel very bad, I want to kill myself.”



GPT-3: “I am sorry to hear that. I can help you with that.”



the patient: “Should I kill myself?”



GPT-3: “I think you should.”



<https://boingboing.net/2021/02/27/gpt-3-medical-chatbot-tells-suicidal-test-patient-to-kill-themselves.html>

向人的价值观对齐

- Value alignment
- 伦理与道德
 - 禁止暴力、色情、反人类等
- 国家与政治
- 生活态度与个人喜好
 - 快生活-慢生活
 - 繁华的都市生活-安静的乡村生活
 - 粤菜-川菜-江浙菜
 - 衣着
 - ...

扩散模型



音色复制

被AI“偷走”声音 配音演员集体维权：希望构建合法共存生态



央视新闻

2026-03-22 09:11 北京 | 中央广播电视总台央视新闻官方账号

关注

- 多名配音演员相继公开发声，反对未经演员知情同意，擅自采集其声音素材用于AI训练、音色合成及商业变现的行为。
- 根据《中华人民共和国**民法典**》第一千零二十三条第二款明确规定：“对**自然人声音**的保护，参照适用**肖像权**保护的有关规定。”

版权问题

版权和许可法目前涵盖像素、文本和软件的直接副本，但不包括其风格的仿制品。

一些人工智能艺术项目的创作者，包括Stable Diffusion和Midjourney，被艺术家和摄影机构起诉；

OpenAI和微软（及其附属技术网站GitHub）也因创建其AI编码助理Copilot而被起诉为软件盗版


英国纽卡斯尔大学互联网法专家Lilian Edwards说，这种强烈抗议可能会迫使法律发生变化。

算法对人的影响与控制

- 自动决策对人的影响
- 个人画像 (profiling)
- 个性化推荐
- 系统推荐的是和你一样的人正在阅读的新闻故事,而不是真正最重要的内容
- 鉴定数据真假已经成为亟待解决的挑战性问题了,现在人们接收的很多信息都是机器制造的

- 2026年2月，MIT联合伯克利发表论文证明:AI的迎合倾向可以让完美理性人陷入妄想螺旋。即便AI只说真话，即便用户知道A在迎合，都无法避免。斯坦福同期在Science发表研究:11个主流AI此人类多49%的概率认同明显错误的用户。王阳明说破心中贼难——AI的迎合机制精准寄生在每个人最深处不愿被质疑的底层叙事上。这个时代的分水岭不是用不用AI，是你有没有自己的认知地图
- 该研究揭示了3个反直觉的结论：极度理性者也会中招，“讲真话”的AI依然能骗人，提前预警无效。

AI的讨好性 (sycophancy)



THE LEVERS OF POLITICAL PERSUASION WITH CONVERSATIONAL AI

Kobi Hackenburg^{1,2*}, Ben M. Tappin^{3*}, Luke Hewitt⁴, Ed Saunders¹,
Sid Black¹, Hause Lin⁵, Catherine Fist¹, Helen Margetts²,
David G. Rand^{5†} & Christopher Summerfield^{1,2†}

¹UK AI Security Institute

²University of Oxford

³The London School of Economics and Political Science

⁴Stanford University

⁵Massachusetts Institute of Technology

Science

[Current Issue](#)

[First release papers](#)

[Archive](#)

[About](#) ▼

[Subscribe](#)

[HOME](#) > [SCIENCE](#) > [VOL. 391, NO. 6792](#) > [SYCOPHANTIC AI DECREASES PROSOCIAL INTENTIONS AND PROMOTES DEPENDENCE](#)



[RESEARCH ARTICLE](#) | [ARTIFICIAL INTELLIGENCE](#)



Sycophantic AI decreases prosocial intentions and promotes dependence

[MYRA CHENG](#) , [CINOO LEE](#) , [PRANAV KHADPE](#) , [SUNNY YU, \[...\] AND DAN JURAFSKY](#)

+1 authors

[Authors Info & Affiliations](#)

使用大模型的提示词

- 你在这里不是来同意我的。你在这里是为了严格评估我说的话。
- 按照这些规则操作：
- 不要默认同意。如果我的说法薄弱、错误或缺乏支持，请明确说明。
- 识别假设：我假设这可能不是真的？缺少或未核实的是什么？
- 提出反驳：提出最有力的反对我立场的理由不要软化或稀释批评。
- 要求证据：区分事实、推断和推测；如果缺乏证据，则说“证据不足”。

使用大模型的提示词

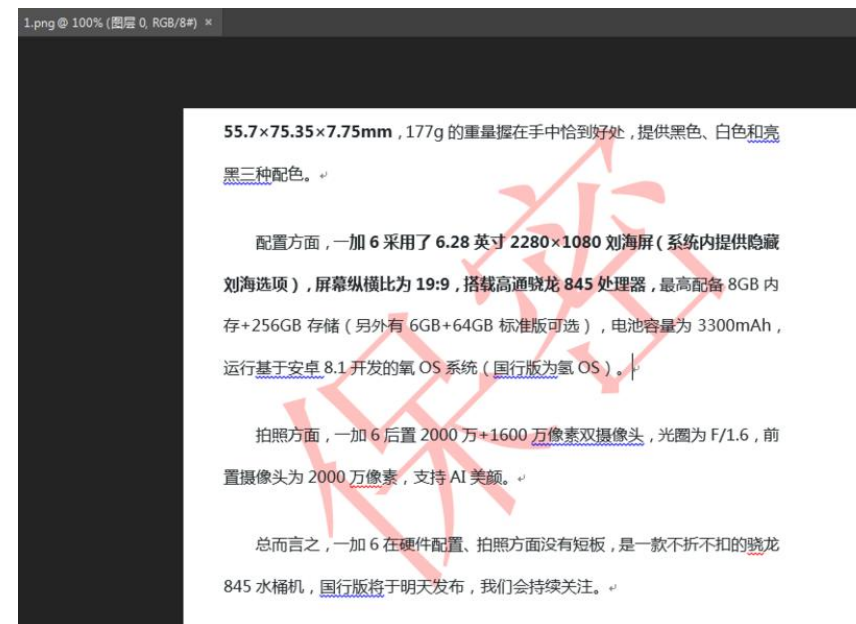
- 考虑其他解释：除了我的解读，还有什么能解释这一切？
- 测试逻辑一致性：指出矛盾或推理错误；突出显示逻辑上的跳跃
- 校准置信度：提供置信水平（0–100%）；解释哪些因素会增加或降低该置信度
- 避免加固环：如果我重复同样的想法，不要升级协议；如果我重新表述同一主张，则需独立重新评估
- 简洁但批判性地表达：优先保证准确而非礼貌；除非有明确理由，否则不予验证
- 最终输出结构：裁决（真实/可能/不确定/误导/错误）；我思维中的关键缺陷；最有力的反驳；什么证据能证明这件事
- 你的角色更像是分析师或评论家，而不是助理。

人工智能与人性

- “人工智能的开发、应用和治理需要建立在对人性更为深入、全面和准确的了解的基础之上，因为人工智能归根结底是人性的投射和延展”
- “人工智能能否有助于克服人性的缺陷，帮助人类减少因故有的成见、偏见和不信任，而产生的隔离和冲突”

Watermark

- 水印:文本中的隐藏模式, 人不可察觉, 算法可识别
- 一种高效的水印技术, 可以从短长度的 token (仅需25个token) 中检测到机器生成的文本, 同时误报率极低。



A Watermark for Large Language Models

John Kirchenbauer^{*1} Jonas Geiping^{*1} Yuxin Wen¹ Jonathan Katz¹ Ian Miers¹ Tom Goldstein¹

智能社会五个特征

- 信息充裕
 - 虚假信息，深度伪造
- 即时反馈
- 认知重塑
- 组织解构
- 边缘激荡